

基于深度语义分割的隧道渗漏水智能识别

周 中^{1,2}, 张俊杰¹, 龚琛杰^{1,2}, 丁昊晖¹

(1. 中南大学 土木工程学院, 湖南 长沙 410075; 2. 湖南铁院土木工程检测有限公司, 湖南 长沙 410075)

摘要:为解决现有隧道渗漏水检测方法中存在的检测精度较低、抗干扰能力较差、检测速度较慢的问题,提出了一种基于深度语义分割的隧道渗漏水图像识别算法。该算法以DeepLabv3+语义分割算法为基础,首先采用轻量化分类网络EfficientNetv2作为主干网络,在减少网络参数的同时,提升了识别精度;其次融合卷积注意力机制模块,通过增大图像中有效通道的权重,提升网络对于渗漏水特征信息的提取能力;进而从图像识别精度、模型内存和处理速度3个方面与DeepLabv3+, PSPnet, Unet等传统语义分割算法进行对比实验。研究表明:提出算法的平均像素准确率和平均交并比分别为93.99%, 89.87%, 模型大小仅为33.4 MB, 图像处理速度可达39.87 f/s。相较于3种对比算法,构建算法在隧道渗漏水病害检测的精度和效率上都有显著提升,且具有更为优越的边缘分割效果以及抗干扰能力,适用于复杂环境下的隧道渗漏水检测任务,能够更好地满足工程检测需求。

关键词:隧道工程; 渗漏水; 语义分割; 深度学习; 神经网络

中图分类号: U 45

文献标识码: A

文章编号: 1000-6915(2022)10-2082-12

Automatic identification of tunnel leakage based on deep semantic segmentation

ZHOU Zhong^{1,2}, ZHANG Junjie¹, GONG Chenjie^{1,2}, DING Haohui¹

(1. School of Civil Engineering, Central South University, Changsha, Hunan 410075, China; 2. Hunan Tiesyuan Civil Engineering Testing Co., Ltd., Changsha, Hunan 410075, China)

Abstract: Aiming to solve the challenges of low detection accuracy, poor anti-interference ability and slow detection speed in the traditional tunnel leakage detection methods, a depth semantic segmentation algorithm for tunnel leakage is proposed on the basis of the DeepLabv3+ semantic segmentation algorithm. Firstly, the lightweight classification network EfficientNetv2 is used as the backbone network, which enhances the recognition accuracy while reduces network parameters. Secondly, Convolutional Block Attention Module(CBAM) is integrated to increase the weight of the effective channels in the image, thereby improving the ability of extraction of leakage feature information. Traditional semantic segmentation algorithms, including DeepLabv3+, PSPnet and Unet, are used for comparative experiments from three aspects: image recognition accuracy, model size, and detection speed. The results show that the mean pixel accuracy(mPA), mean intersection over union($mIoU$), model size and image processing speed(FPS) of the proposed algorithm are 93.99%, 89.87%, 33.4 MB and 39.87 f/s, respectively. Compared with the three comparison algorithms, the detection accuracy and efficiency of the proposed algorithm have been significantly improved. Furthermore, the proposed algorithm has better edge segmentation effect and

收稿日期: 2022-01-04; **修回日期:** 2022-03-26

基金项目: 国家自然科学基金资助项目(50908234); 湖南省自然科学基金资助项目(2020JJ4743); 湖南铁院土木工程检测有限公司开放课题(202106) Supported by the National Natural Science Foundation of China(Grant No. 50908234), Natural Science Foundation of Hunan Province, China(Grant No. 2020JJ4743) and Open Project of the Hunan Tiesyuan Civil Engineering Testing Co., Ltd.(Grant No. 202106)

作者简介: 周 中(1978-), 男, 2006年于中南大学岩土工程专业获博士学位, 现任副教授, 主要从事隧道与地下工程方面的教学与研究工作。E-mail: 369144091@qq.com。通讯作者: 龚琛杰(1990-), 男, 博士, 现任副教授。E-mail: gongcj@csu.edu.cn

DOI: 10.13722/j.cnki.jrme.2022.0016

anti-interference ability, which is suitable for tunnel leakage detection tasks in complex environments, so as to better meet the needs of engineering detection.

Key words: tunnelling engineering; leakage; semantic segmentation; deep learning; neural network

1 引言

随着新型城镇化和交通强国战略的有力推进,隧道及地下工程作为基本建设的主要组成部分迎来了发展机遇,海量隧道工程建成并投入运营。作为埋置于地下岩土介质中的隐蔽工程,复杂运营环境(围岩压力变异、地下水、长期差异沉降、温度变化、内部车辆荷载、临近工程扰动)作用下,隧道衬砌将会出现各种类型的病害^[1-2]。其中,渗漏水是隧道中最为常见的病害之一,如果没有对渗漏水及时进行处理,将很有可能造成混凝土腐蚀、衬砌破裂、冻胀等危害,进而影响隧道的运营安全^[3-5]。因此,隧道衬砌渗漏水病害的科学检测和治理,对于保障隧道的运营安全具有重要意义。

目前,传统的隧道病害检测方式以人工巡检为主。该方式不仅效率低下,并且检测结果严重受到检测人员主观性的影响,在实际检测过程中经常出现漏检和错检的现象^[6-7]。近年来,随着计算机技术的快速发展,图像处理技术和深度学习算法被逐渐应用于结构表面病害的检测中^[8-9]。图像处理技术虽然能快速识别隧道衬砌病害,但是其识别精度严重受到环境因素的干扰^[10],适用性较窄。而基于深度学习的病害检测算法相较于其他检测算法具有更加出色的特征提取能力、自动化水平以及更好的抗干扰能力,因此具有更好的病害识别精度。然而,该类方法应用至实际隧道工程依旧面临着训练数据样本不足、识别类型单一、检测效率低下、鲁棒性较差的挑战。本文基于深度学习框架,构建出一种准确、快速、高效的隧道渗漏水识别算法。

2 相关研究工作

2.1 基于图像处理的隧道衬砌病害识别算法

基于图像处理技术的隧道衬砌病害(渗漏水、裂缝等)识别算法主要分为单一图像处理算法和融合图像处理算法两类。经典的单一图像处理算法包括阈值算法^[11]、边缘算法^[12]、区域算法^[13]、匹配算法^[14]等,单一图像处理算法能够在特定条件实现对渗漏水病害的快速识别,但是该类算法的识别精度严重受到噪声和病害图像清晰度的制约,难以将病害从

背景中完整地区分出来。融合算法通过有机融合多种单一图像处理算法的方式,提升了算法的过滤能力,从而实现了对于较为复杂背景条件下病害的识别。Y. Fujita 等^[15]首先采用减法和线性强调法两种图像预处理方法以减弱阴影的影响,突出病害结构,然后采用阈值算法将病害从背景中分离出来。刘学增等^[16]将灰度处理、阈值算法、形态修正等方法进行结合,构建了一种新的渗漏水图像分割方法。彭斌等^[17]将全景展开技术与多种数字图像处理算法相结合实现了对矿山法隧道衬砌渗漏水的识别。然而这类算法的泛化能力较差,难以适应隧道中的光照和背景的不断变化。因此,在检测过程中需要不断的人为进行参数调节,严重影响了隧道衬砌病害的检测效率。

2.2 基于深度学习的隧道衬砌病害识别算法

基于深度学习的隧道衬砌病害检测算法主要分为三类,分别是图像分类算法、目标检测算法、语义分割算法。其中,图像分类算法是目标检测算法、语义分割算法的重要基础,经典的图像分类算法包括 AlexNet^[18], GoogLeNet^[19], VGG^[20], ResNet^[21]等。借助迁移学习,即可采用该类算法进行隧道衬砌病害的分类。薛亚东和李宜城^[22]采用卷积神经网络(CNN)实现了对盾构隧道中的渗漏水、裂缝等衬砌病害的分类;W. Wang 等^[23]从网络结构、裂缝数据、分类方法和环境条件 4 个方面进行评估,采用 Inception-ResNet-v2 网络将裂缝图像分为 3 个严重程度级别。W. R. L. Silva 和 D. S. Lucena^[24]采用 VGG16 作为分类模型,研究了学习速率、最后一个完全连通层的节点数和训练数据集大小等参数对模型性能的影响,提升了对结构病害的分类准确率。但是图像分类算法无法识别衬砌病害的具体位置,在病害检测领域通常被用作目标检测算法和语义分割算法的主干特征提取网络。

在图像分类算法的基础上,目标检测算法也被逐渐提出,主要有以 SSD^[25], YOLO 系列^[26-28]为代表的单阶段神经网络以及以 RCNN^[29], Fast-RCNN^[30], Faster-RCNN^[31]为代表的双阶段神经网络。单阶段网络相比双阶段网络结构更加精简,因此在运算速度上具有较为明显的优势,但是其算法的目标识别精度一般不如双阶段网络。目前已有学者将其应用至结构病害的识别中。任松等^[32]使用单阶段网络 SSD 提取隧道衬砌裂缝的特征,实现了对公路

隧道衬砌裂缝的准确识别。J. Deng 等^[33]采用双阶段网络 Faster-RCNN 实现了对复杂背景条件下桥梁裂缝的检测。Z. Zhou 等^[34]采用深度可分离卷积以及 EfficientNet 主干特征提取网络对 YOLOv4 算法进行改进,有效提升了公路隧道衬砌病害的识别精度和效率。相较于图像分类算法,目标检测算法不仅能够实现对隧道衬砌病害进行分类,还能够实现病害区域的定位,但是该算法缺乏对病害具体形态特征的识别。

语义分割算法能够实现对目标具体形态特征的精确识别,通过对输入图像进行像素级分类,对像素进行分割,从而识别出图像中目标的轮廓。C. Feng 等^[35]采用可分离卷积和非对称卷积构建了 STDD 网络,并实现了隧道中裸露钢筋的准确识别。黄宏伟和李庆桐^[36]采用 FCN 网络实现了对盾构隧道渗漏水病害的分割识别。L. Zhang 等^[37]提出了一种改进的基于 Unet 的自动像素级裂纹检测方法 CrackUnet,并研究了数据集大小和模型深度对训练时间、检测精度和速度的影响。

综上所述,语义分割算法能够更好的对隧道衬砌病害进行精细化识别,但是该类算法要被真正的应用至实际隧道渗漏水的检测中依旧还面临着以下问题:

(1) 采集足够多的高分辨率、背景丰富的隧道渗漏水图像需要大量的隧道作为图像采集的工程支撑,且目前结构病害开源数据集的对象大多数为裂缝。因此,现有的深度学习算法大多数集中于对裂缝病害的识别,而对于渗漏水的研究较少。

(2) 基于语义分割算法所构建的隧道病害识别模型往往需要较大的存储内存,导致检测速度难以满足隧道衬砌病害实时快速检测的要求。

(3) 现有的研究多集中于实验室简单环境下人工预设病害的识别,而对于复杂背景和多变光照的隧道运营场景,现有算法针对实际隧道渗漏水识别的有效性有待进一步验证。

(4) 现有隧道渗漏水识别研究多针对单一的山岭钻爆法隧道或地铁盾构法隧道,而对于不同工法隧道衬砌渗漏水图像,缺少一种稳健算法对上述复杂渗漏水病害进行识别。

针对上述问题,本文以 DeepLabv3+语义分割算法为基础,融合 EfficientNetv2 主干特征提取网络和卷积注意力机制模块(convolutional block attention module, CBAM),提出了一种基于深度语义分割的隧道渗漏水图像识别算法,本文的主要贡献如下:

(1) 通过对多个高速公路以及地铁隧道进行病害图像采集,构建了具有充足数量且背景条件丰富的高质量隧道渗漏水数据集。

(2) 采用 EfficientNetv2 代替 Xception 作为 DeepLabv3+的主干特征提取网络,在减小模型参数的同时,提升了对隧道渗漏水检测的精度。

(3) 通过引入卷积注意力机制模块(CBAM),增加有效通道的权重,提升网络对于目标信息的提取能力,实现了复杂背景条件下隧道渗漏水的特征的精确提取。

(4) 利用构建的隧道渗漏水数据集对本文提出算法进行训练,实现了对不同工法隧道衬砌渗漏水图像的准确识别。

3 隧道渗漏水图像分割算法

3.1 DeepLabv3+算法概述

DeepLabv3+算法^[38]主要由编码器和解码器两部分组成,网络结构如图 1 所示。编码器由主干特征提取网络 Xception^[39]和空洞卷积池化金字塔(atrous spatial pyramid pooling, ASPP)组成,作用是提取目标的高级特征,从而获得更多的语义信息。解码器由多个卷积层和上采样层组成,主要作用是提取目标的低级特征从而恢复编码过程中丢失的边界信息,提升目标分割的细节。DeepLabv3+算法进行目标分割的主要流程如下。

首先,图像经过预处理和尺寸归一化后大小被统一调整为 512 Pixel×512 Pixel,为了避免图像尺寸变化带来失真问题,在尺寸归一化的过程中首先保持原图像的长宽比不变,对图像进行等比缩小,之后再对剩余区域进行纯色填充。处理后的图像首先被输入至 Xception 主干网络中进行特征提取,输出得到一个低级特征层和一个高级特征层。其中,高级特征层被输入至 ASPP 结构中进行特征加强,在该结构中,多个具有不同扩张率的膨胀卷积层^[40]将会对高级特征层进行不同尺度的采样,形成融合多尺度语义信息的加强特征层。然后,加强特征层经过一次 1×1 的卷积降维后被输入至解码器。在解码器中, Xception 网络输出的低级特征层首先经过 1×1 卷积降维,之后与通过内插上采样操作放大 4 倍后的加强特征层进行特征融合得到新的特征层。最后,该特征层依次经过 3×3 卷积和 4 倍上采样输出得到语义分割结果。

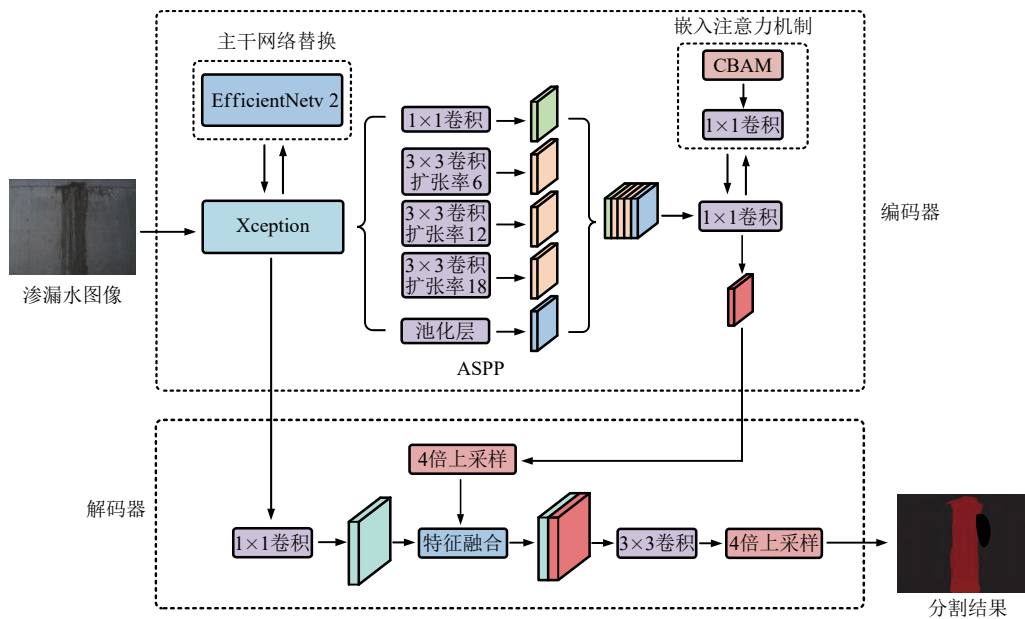



图 1 DeepLabv3+网络结构与改进方法

Fig.1 Network structure of DeepLabv3+ and the improvement methods

值得说明的是,膨胀卷积层通过向卷积核中添加空洞的策略有效的扩大了感受野,只需要采用大小为 n 的卷积核就能够获得大小为 $(n-1) \times d + 1$ (d 为扩张率)的卷积核的感受野,图 2 为标准卷积与膨胀卷积的原理对比图。因此,膨胀卷积能够在不改变图像输出特征图的尺寸情况下,增加网络的感受野,减少 DeepLabv3+网络在特征提取过程中目标信息的丢失,从而有效解决传统语义分割算法中使用连续池化和卷积下采样导致的目标特征信息的损失问题。此外,相较于同样具有膨胀卷积的 DeepLab 系列网络^[41-42],DeepLabv3+通过融合 Xception 主干特征提取网络并设计了一种简单高效的解码-编码结构,进一步提升了图像的分割精度。基于上述优势,本文选择 DeepLabv3+语义分割算法作为本文算法的基础,并针对隧道渗漏水识别任务进行改进,以实现复杂环境下渗漏水区域的高精度快速识别。

3.2 改进隧道渗漏水图像分割算法

DeepLabv3+算法凭借其独特的空洞卷积池化金字塔结构以及良好的编码解码能力实现了较高的



(b) 膨胀率为 2 的膨胀卷积

图 2 标准卷积与膨胀卷积

Fig.2 Standard convolution and dilated convolution

图像分割精度,然而针对复杂环境条件下隧道渗漏水的识别任务,该算法依旧存在抗干扰能力不足、边缘细节丢失、检测速度不能满足实时检测要求等问题。因此本文以 DeepLabv3+为基础算法,通过融合 EfficientNetv2 主干特征提取网络^[43]和卷积注意力机制模块(CBAM)^[44]对算法进行改进,主要改进策略如下。

采用 EfficientNetv2 网络取代 Xception 网络作为 DeepLabv3+的主干特征提取网络,在减小模型参数的同时,提升对隧道渗漏水检测的精度。

在编码器中的 ASPP 结构之后引入 CBAM 注意力机制,对通过膨胀卷积得到的融合多尺度语义信息的加强特征层增加注意力机制,提升有效通道的权重,加强网络对于目标信息的提取能力,减弱融合后冗余特征的影响并解决复杂背景条件下隧道渗漏水的特征难以提取的问题。

下面将从 EfficientNetv2 和 CBAM 的原理为切入

点详细的对上述改进策略的有效性进行理论分析。

3.2.1 EfficientNetv2 主干特征提取网络

基于深度学习的检测算法精度的主要影响因素为网络的宽度、深度和图像分辨率。如果只对其中某个参数进行调整,模型的精度很快就会达到饱和,导致网络性能很难有明显提升。为了解决这个问题,谷歌提出了一种简明高效的复合缩放方法^[45],该方法通过复合系数 ϕ 统一调整网络的宽度、深度和图像分辨率,调整原则如下:

$$d = \alpha^\phi \quad (1)$$

$$w = \beta^\phi \quad (2)$$

$$r = \gamma^\phi \quad (3)$$

式中: d 为网络的深度; w 为网络的宽度; r 为图像的分辨率; α , β , γ 为网格搜索得到的常数。复合系数的限制条件:

$$\alpha\beta^2\gamma^2 \approx 2 \quad (4)$$

$$\alpha \geq 1, \beta \geq 1, \gamma \geq 1 \quad (5)$$

基于上述方法,谷歌构建了 EfficientNet 和 EfficientNetv2 分类网络,相较于已有的分类网络, EfficientNet 系列网络不仅具有更小的网络参数,还拥有更高的精度。其中, EfficientNetv2 还在图像推理速度上具有明显的优势。

EfficientNetv2 主要由移动翻转瓶颈卷积结构(MBConv)和融合移动翻转瓶颈卷积结构(Fused-MBConv)模块组成,其结构如图3所示(图中, Conv 为卷积层; H , W , C 分别为图像的高度、宽度以及通道数; SE 为 Squeeze-and-Excitation 注意力机制的缩写; Depthwise 为深度可分离卷积层)。MBConv 由 2 个 1×1 标准卷积、SE 注意力机制模块、深度可分离卷积和残差边组成。其中,深度可分离卷积的设置大大减小了模型的参数量。Fused-MBConv 采用 3×3 的标准卷积替换了 MBConv 中的 3×3 深度可分离卷积和 1×1 标准卷积。相较于 MBConv, Fused-MBConv 虽然参数量更多,但是具有更强的特征提取能力和图形推理速度。M. Tan 和 Q. Le^[43]通过神经架构搜索方法(NAS)得到了 Fused-MBConv 和 MBConv 的最佳组合,从而充分发挥两种模块的优势,实现精度、模型参数量以及推理速度的平衡。该组合下 EfficientNetv2 的结构参数如表1所示。

相较于 DeepLabv3+中的 Xception 主干网络, EfficientNetv2 网络不仅具有更小的模型参数量,并且在多项分类任务中表现出更加优异的准确率和效率。因此本文考虑引入 EfficientNetv2 替换 Xception 作为主干网络,以此来提升隧道渗漏水的识别精度和效率。




图3 MBConv 与 Fused-MBConv 结构

Fig.3 Structure of MBConv and Fused-MBConv

表1 EfficientNetv2 网络结构参数

Table 1 Network structure parameters of EfficientNetv2

结构	分辨率	通道数	层数
Conv 3×3	224×224	24	1
Fused-MBConv1, $k \times 3$	112×112	24	2
Fused-MBConv4, $k \times 3$	112×112	48	4
Fused-MBConv4, $k \times 3$	56×56	64	4
MBConv4, $k \times 3$	28×28	128	6
MBConv6, $k \times 3$	14×14	160	9
MBConv6, $k \times 3$	14×14	272	15
Conv2D & Pooling & FC	7×7	1 792	1

注: MBConv 尾部数字 1 和 6 为倍率因子,即输入特征层的通道数扩充的倍数; k 为卷积核大小; Pooling 为池化层; FC 为全连接层。

3.2.2 卷积注意力机制模块

卷积注意力机制模块(CBAM)能够通过对特征层中有效的特征通道的权重进行放大,使得模型能够更好的区分出目标与背景,从而解决复杂背景条件下隧道渗漏水特征难以提取的问题。CBAM 的结构如图4所示,由通道注意力模块(CAM)和空间注意力模块(SAM)两个子模块构成。

图像特征层 F 首先被输入至通道注意力模块,并行经过全局平均池化和全局最大池化,得到 2 个不同的空间语义算子,并通过共享感知机对两者进行计算,随后将计算所得的 2 个通道注意力特征向量相加融合,最后通过 Sigmoid 函数输出得到通道注意力向量 M_c , M_c 与 F 相乘得到修正特征层 F_1 。计算过程如下所示:

$$M_c = \sigma(MLP(Avg(F)) + MLP(Max(F))) \quad (6)$$




图 4 CBAM 结构图

Fig.4 Structure of CBAM

$$F_1 = M_c F \quad (7)$$

式中: MLP 为共享感知机, Avg 为全局平均池化; Max 为全局最大池化, σ 为 Sigmoid 激活函数。

F_1 被输入空间注意力模块, 首先沿着通道维度进行全局平均池化和全局最大池化, 得到 2 个不同的通道语义算子, 将两者进行拼接后, 依次经过 7×7 的卷积操作和 Sigmoid 函数, 得到空间注意力向量 M_s , M_s 与 F_1 进行相乘, 输出得到最终的修正特征层 F_2 , 计算过程如下所示:

$$M_s = \sigma(f^{7 \times 7}([\text{Avg}(F); \text{Max}(F)])) \quad (8)$$

$$F_2 = M_s F_1 \quad (9)$$

通过施加空间注意力和通道注意力, CBAM 能够放大特征层中有效通道的权重, 从而增强了隧道渗漏水病害特征的语义信息, 并抑制衬砌的复杂背景信息的干扰, 使网络在生成特征层的过程中更加关注病害目标的特征信息。通过这种方式, 可以有效缓解隧道中衬砌背景条件复杂、光照条件多变条件下渗漏水识别精度差的问题。因此, 本文考虑将 CBAM 引入至 DeepLabv3+网络中, 以提升模型的

抗环境干扰能力。此外, CBAM 在网络中的位置同样对于模型性能具有一定的影响, 考虑到经过 ASPP 多尺度融合后得到的特征层不但包含丰富的全局和局部目标语义信息, 还包含部分冗余特征信, 本文将 CBAM 的位置设置在 ASPP 结构和 1×1 标准卷积之间, 借助注意力机制减少融合后冗余特征的影响, 提高融合后特征的利用率。

4 隧道渗漏水数据集

4.1 数据集构建


课题组对国内十余座公路矿山法、盾构法隧道和地铁盾构隧道进行了病害检测, 通过摄影拍照的方式收集了共 486 张隧道衬砌渗漏水图像, 图像的分辨率范围为 $600 \sim 3\,000$, 代表性图像如图 5 所示。可以看出, 本文收集的隧道渗漏水图像具有丰富的背景条件(不同照明、管线干扰、其他病害影响、干渍、噪声), 能够真实反映实际运营隧道场景, 从而保证训练后的网络模型具有良好的鲁棒性。



图5 隧道衬砌典型渗漏水图像

Fig.5 Typical images of tunnel lining leakage

为进一步扩充数据集的数量以及多样性,防止网络训练过程中出现过拟合的现象,本文采用空间级变化(旋转、翻转、裁剪、变形缩放等)、像素级变化(模糊、噪声、亮度调整、对比度调整等)两类数据增强方式对已有隧道衬砌渗漏水图像进行处理,将数据集扩展到 900 张图像,部分数据增强方式如图 6 所示。随机选取扩充后数据集的 720 张隧道渗漏水图像作为训练集;选取 90 张隧道渗漏水图像作为验证集;剩余的 90 张隧道渗漏水图像则作为测试集。



翻转 旋转 裁剪 变形

(a) 空间级变化



噪声 颜色干扰 亮度调整 对比度调整


(b) 像素级变化

图6 数据集扩充方法

Fig.6 Expansion method of data set

4.2 数据集标注

采用 Labelme 标注软件^[46]对本文数据集中的渗漏水病害进行像素级标注,形成包含渗漏水标签的轮廓位置和标签名称等信息的 JSON 文件,并通过软件内置函数进行信息提取,形成可视化标签图像,用于后续模型的训练以及测试。其中,隧道渗漏水区域像素的标签颜色设置为红色,背景区域像素的标签颜色设置为黑色。图 7(a)为 Labelme 软件标注过程,图 7(b)为标注后生成的标签图像。



(a) 标注过程

(b) 标签图像

图7 图像标注方法

Fig.7 Method of image annotation

5 隧道渗漏水图像分割实验

为了验证本文提出的隧道渗漏水分割算法的有效性,选用 DeepLabv3+, PSPnet, Unet 三种语义分割算法进行对比实验。实验主要包括模型训练和模型测试 2 个阶段。第 1 个阶段中,训练集用于对各网络模型进行训练,验证集用于计算训练损失。第 2 个阶段中,利用测试集对各模型的综合性能进行评估。

5.1 实验环境

实验算法通过 Python 3.9 计算机编程语言和 PyCharm 平台中的 Pytorch1.8.0 模块实现。实验系统为 Windows 10,运行内存为 16 GB, GPU 为 NVIDIA GeForce RTX 3060×3 (12 GB)。

5.2 评估指标

5.2.1 训练指标

损失值(Loss)用于判断网络模型训练是否收敛。由于本文的识别对象为隧道渗漏水,属于二分类语义分割任务,因此存在正负样本分布不均的问题,采用传统的交叉熵损失函数会导致模型对于困难样本(渗漏水)的分割性能较差。为了解决该问题,选取 Focal Loss^[47]作为本文模型以及 DeepLabv3+, PSPnet, Unet 对比模型的损失函数,计算公式如下:

$$L_{\text{Focal}} = -(1 - P_t)^{\alpha} \lg(P_t) \quad (10)$$

式中: P_t 为预测类别为真实类别的概率。 P_t 越大,

说明分类的置信度越高, 代表样本越易分; P_i 越小, 则分类的置信度越低, 代表样本越难分。

相较于交叉熵损失函数, Focal loss 增加了调节因子 ω 。对于简单样本, P_i 接近于 1, $(1-P_i)^\omega$ 越接近于 0, 此时简单样本在损失函数中所占的权重也接近于 0。而对于困难样本, P_i 接近于 0, $(1-P_i)^\omega$ 越接近于 1, 此时困难样本在损失函数中所占的权重也接近于 1, 在损失函数占主导作用, 模型对于困难样本的识别准确率也因此得到了明显提升。为了得到适合本文数据集的 ω 大小, 采用 T. Y. Lin 等^[47]给出的 5 种 ω 取值 0, 0.5, 1, 2, 5 分别对各网络模型进行训练以及测试, 测试结果表明各网络模型 ω 的最优取值均为 2。

5.2.2 测试指标

测试指标分为精度指标和效率指标两类。其中, 本文模型的精度指标包括平均像素准确率(mean pixel accuracy, mPA)和平均交并比(mean Intersection over Union, $mIoU$)。 mPA 表示正确识别的像素个数与图像的像素总量的比值, 计算公式如下:

$$mPA = \frac{\sum_{i=1}^N \frac{X_{ii}}{T_i}}{N} \quad (11)$$

式中: N 为包括背景在内的类别总数; X_{ii} 为识别为 i 类、实际为 i 类目标的像素; T_i 为 i 类目标像素的总数量。

交并比是指预测值与真实值的交集与并集之比, $mIoU$ 为每一类交并比的平均值, 计算公式如下:

$$mIoU = \frac{\sum_{i=1}^N \frac{X_{ii}}{\sum_{j=1}^N X_{ij} + \sum_{j=1}^N X_{ji} - X_{ii}}}{N} \quad (12)$$

式中: X_{ij} 为识别为 j 类、实际为 i 类目标的像素; X_{ji} 为识别为 i 类、实际为 j 类目标的像素。

效率指标决定着模型嵌入至移动设备后, 能否实现对隧道渗漏水的实时识别。本文选择模型的大小(model size, MS)和图像处理速度(frames per second, FPS)为各网络模型的效率指标。其中, FPS 的计算公式如下:

$$FPS = \frac{N_{\text{picture}}}{T_{\text{total}}} \quad (13)$$

式中: T_{total} 为图片检测的总时间, N_{picture} 为被检测图片的总数量。

5.3 超参数设置

为了尽可能保证设置的超参数能够充分发挥各

网络的性能, 本文采用网格搜索^[48]的方法对各网络的批量大小($Batch\text{-}size$)、学习率($Learning\ rate$)、动量($Momentum$)进行了参数寻优, 定义验证集的损失为优化过程中的目标函数来判断参数组合是否为最优, 最终确定各超参数的优化结果如表 2 所示。此外, 本文的训练次数($Epochs$)设置为 200 次, 以保证各网络在训练过程中均能够达到收敛。

表 2 网络超参数

Table 2 Network hyperparameters

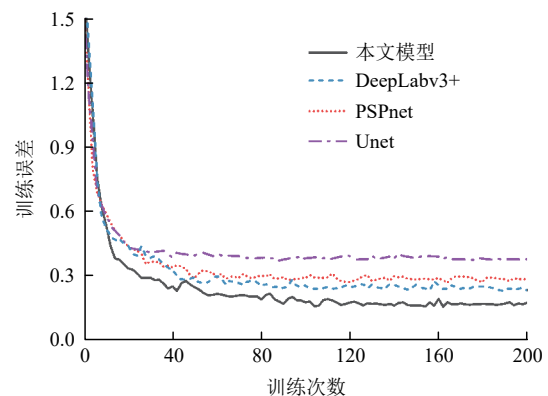
参数	$Batch\text{-}size$	$Learning\ rate$	$Momentum$
A	16	1×10^{-3}	0.94
B	8	5×10^{-4}	0.94
C	8	5×10^{-4}	0.95
D	4	1×10^{-3}	0.92

注: A 为本文网络; B 为 DeepLabv3+网络; C 为 PSPnet 网络; D 为 Unet 网络。

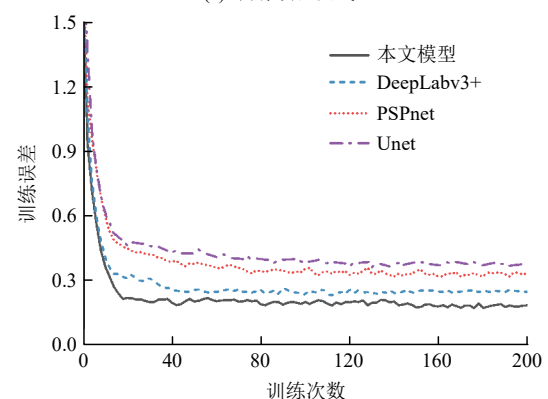
6 实验结果及分析

6.1 训练结果

在对各网络进行训练的过程中, 会实时的记录每一次训练过程的训练误差和验证误差。图 8(a)展示了 4 种模型的训练误差曲线; 图 8(b)展示了 4 种模型的验证误差曲线, 从图中的结果可以看出, 经过 200 次迭代训练后, 各网络的训练和验证误差曲



(a) 训练误差曲线



(b) 验证误差曲线

图 8 4 种模型的误差曲线

Fig.8 Loss curves of the four models

线趋于稳定,表明此时各网络已经收敛。此外,本文提出的算法网络的训练损失最终稳定在 0.17 左右,验证误差最终稳定在 0.18,均优于其余对比网络。且两项误差相差很小,表明本文算法网络在训练过程没有出现过拟合的现象。

6.2 测试结果

采用测试集对训练后的 4 种网络模型的各项性能指标进行测试,测试结果如表 3 所示。

表 3 模型性能评价指标表
Table 3 Evaluation indices of model performance

网络模型	<i>mPA</i> /%	<i>mIoU</i> /%	<i>MS</i> /MB	<i>FPS</i> /%
本文模型	93.99	89.87	33.4	39.87
DeepLabv3+	87.25	84.08	209.5	8.53
PSPnet	78.65	75.25	178.3	21.18
Unet	79.24	76.36	94.9	10.64

由表 3 中结果可知,在精度指标方面,本文模型的 *mPA* 为 93.99%,相较于 DeepLabv3+, PSPnet, Unet 模型分别提升了 6.74%, 15.34%, 14.75%。本文模型的 *mIoU* 为 89.87%,相较于 DeepLabv3+, PSPnet, Unet 模型分别提升了 5.79%, 14.62%, 13.51%。上述结果表明,本文提出的算法模型有效的提升了隧道衬砌渗漏水的分割精度。在效率指标方面,本文模型的大小仅为 33.4 MB,远远小于 DeepLabv3+, PSPnet, Unet 模型。此外,本文模型的 *FPS* 高达 39.87 f/s,相较于 DeepLabv3+, PSPnet, Unet 分别提升了 31.34, 18.69, 29.23 f/s。

为直观体现各模型对隧道渗漏水的分割效果,图 9 展示了隧道衬砌不同背景和光照条件下渗漏水图像的分割结果对比图。第一列为隧道衬砌的原始

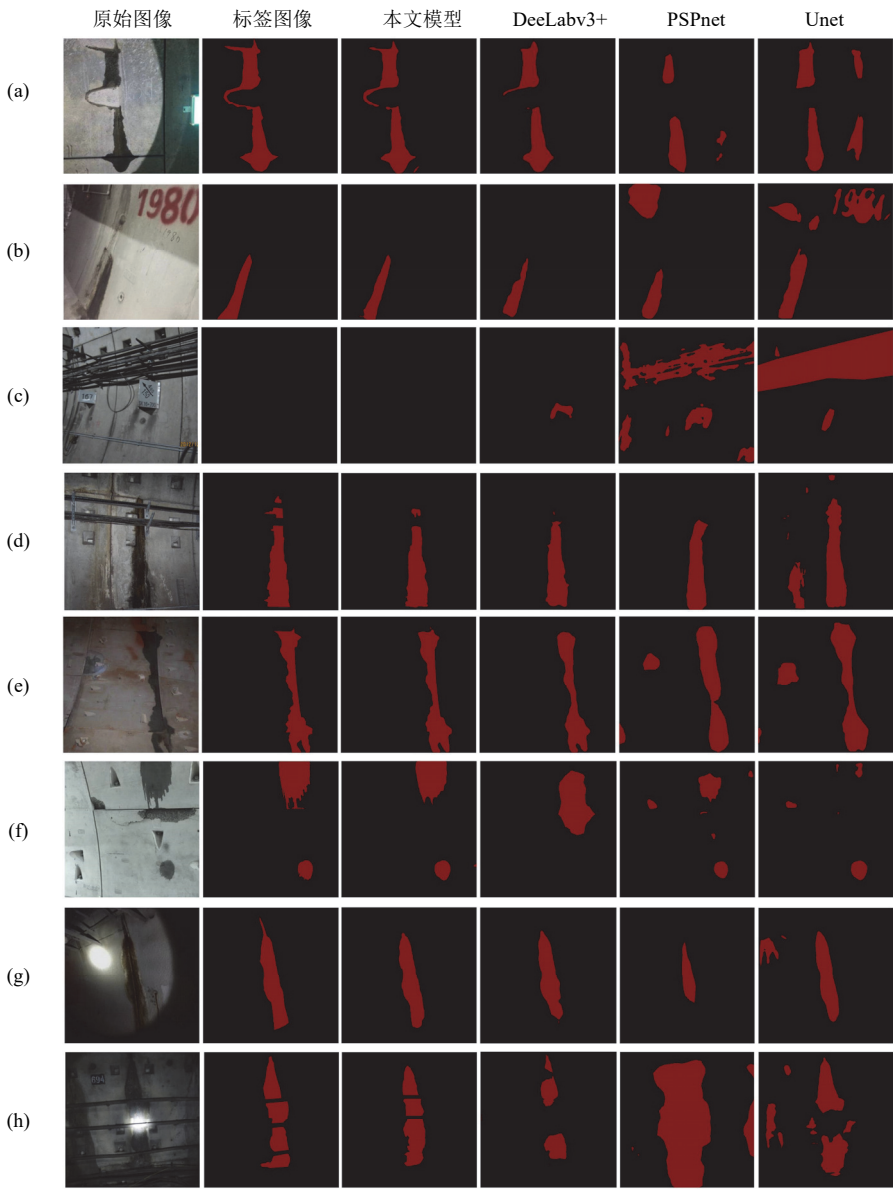


图 9 隧道衬砌渗漏水分割结果
Fig.9 Segmentation results of tunnel lining leakage

图像, 其中, 图 9(a)和(b)为环境条件较为简单的隧道衬砌图像, 图 9(c)和(d)为背景存在管线、标志物等干扰时的隧道衬砌图像, 图 9(e)和(f)为背景中存在其他外观颜色与渗漏水相近的物质干扰时的隧道衬砌图像, 图 9(g)和(h)为光线昏暗时的隧道衬砌图像; 第 2 列为渗漏水目标的标注图像; 第 3~7 列分别为本文模型, DeepLabv3+, PSPnet, Unet 的渗漏水图像分割效果。为了较好的体现出各模型的分割效果, 将图像的背景像素颜色设置为黑色, 所分割的渗漏水像素颜色设置为红色。

从图中可以看出, 对于图 9(a), (b)环境条件较为简单的隧道衬砌图像, 本文网络模型与 DeepLabv3+ 模型的分割效果都较为良好, 能够将绝大部分的渗漏水区域从背景中分割出来, 且本文模型所分割的渗漏水边缘细节更加准确, 而 PSPnet, Unet 模型则出现了较大面积的错误分割现象。对于图 9(c)~(f)背景中存在管线、螺栓孔以及其他外观颜色与渗漏水相近的物质干扰时的隧道衬砌图像, 本文模型几乎没有出现将背景中的干扰错误识别成渗漏水的现象, 而另外 3 种模型均出现了不同程度上的错误分割。由图 9(g), (h)隧道光线昏暗时的渗漏水分割结果可以看出, 即使是在光线昏暗的条件下, 本文模型依旧能够保持了良好的分割效果, 实现对渗漏水形态和位置的准确识别。上述结果表明, 相较于 DeepLabv3+, PSPnet, Unet 模型, 本文模型具有更好的抗环境干扰能力, 能够实现复杂背景和光照条件下隧道渗漏水的精细化分割。

7 工程应用前景

相较于传统的语义分割算法, 本文提出的语义分割算法在隧道渗漏水的识别中具有更高的精度, 能够准确的定位出不同类型隧道渗漏水所处的位置, 实现对渗漏水的形状的像素级分割。此外, 该算法具有优秀的抗干扰能力, 能够在各种光线和背景干扰的环境中保持良好的稳定性, 可直接用于复杂环境的各类铁路、公路、地铁隧道的渗漏水检测任务中。且本文提出的分割模型具有轻量化、效率高的优势, 图像处理速度高达 39.87 f/s, 能够实现病害的实时检测。

基于该算法可以开发相应的软件平台, 将其集成至无人机、智能检测车、爬壁机器人等移动设备中, 借助传感器和无线数据传输等技术实现对实际隧道中渗漏水的自动化实时检测, 从而解决传统的

人工巡检方式中所存在的耗时、效率低, 主观程度高、错检漏检率高等问题, 为隧道病害检测向着智能化方向发展提供理论和技术支持。

8 结 论

本文以 DeepLabv3+语义分割算法为基础, 采用轻量化 EfficientNetv2 作为主干特征提取网络, 并融合 CBAM 注意力机制, 提出了一种基于深度语义分割的隧道渗漏水图像识别算法, 实现了对复杂环境条件下的多类型隧道渗漏水病害的智能化、高精度、快速检测, 主要结论如下:

(1) 在精度指标方面, 本文模型的 mPA 为 93.99%, 相较于 DeepLabv3+, PSPnet, Unet 模型分别提升了 6.74%, 15.34%, 14.75%。本文模型的 $mIoU$ 为 89.87%, 相较于 DeepLabv3+, PSPnet, Unet 模型分别提升了 5.79%, 14.62%, 13.51%。上述结果表明, 本文提出的算法模型有效地提升了隧道衬砌渗漏水的分割精度。

(2) 在效率指标方面, 本文算法模型的大小仅为 33.4 MB, 图像处理速达高达 39.87 f/s, 可以满足移动设备实时检测隧道渗漏水过程中对于图像处理速度的要求。

(3) 相较于其他语义分割模型, 本文模型所分割的渗漏水边缘细节更加准确, 且具有更好的抗干扰能力, 能够有效避免复杂背景条件的影响, 实现对渗漏水位置和形态的准确分割。

参考文献(References):

- [1] ZHOU Z, DING H, MIAO L, et al. Predictive model for the surface settlement caused by the excavation of twin tunnels[J]. Tunnelling and Underground Space Technology, 2021, 114: 104014.
- [2] LEI M, ZHU B, GONG C, et al. Sealing performance of a precast tunnel gasketed joint under high hydrostatic pressures: Site investigation and detailed numerical modeling[J]. Tunnelling and Underground Space Technology, 2021, 115: 104082.
- [3] GONG C, DING W, XIE D. Parametric investigation on the sealant behavior of tunnel segmental joints under water pressurization[J]. Tunnelling and Underground Space Technology, 2020, 97: 103231.
- [4] GONG C, DING W, SOGA K, et al. Failure mechanism of joint waterproofing in precast segmental tunnel linings[J]. Tunnelling and Underground Space Technology, 2019, 84: 334 - 352.
- [5] ZHANG J, LI F, ZENG L, et al. Effect of cushion and cover on moisture

- distribution in clay embankments in southern China[J]. Journal of Central South University, 2020, 27(7): 1 893 - 1 906.
- [6] WEI F, YAO G, YANG Y, et al. Instance-level recognition and quantification for concrete surface bughole based on deep learning[J]. Automation in Construction, 2019, 107: 102920.
- [7] HUANG H, LI Q, ZHANG D. Deep learning based image recognition for crack and leakage defects of metro shield tunnel[J]. Tunnelling and Underground Space Technology, 2018, 77: 166 - 176.
- [8] 鲍跃全, 李 惠. 人工智能时代的土木工程[J]. 土木工程学报, 2019, 52(5): 1 - 11.(BAO Yuequan, LI Hui. Artificial Intelligence for civil engineering[J]. China Civil Engineering Journal, 2019, 52(5): 1 - 11.(in Chinese))
- [9] 刘宇飞, 樊健生, 聂建国, 等. 结构表面裂缝数字图像法识别研究综述与前景展望[J]. 土木工程学报, 2021, 54(6): 79 - 98.(LIU Yufei, FAN Jiansheng, NIE Jianguo, et al. Review and prospect of digital-image-based crack detection of structure surface[J]. China Civil Engineering Journal, 2021, 54(6): 79 - 98.(in Chinese))
- [10] WEI F, YAO G, YANG Y, et al. Instance-level recognition and quantification for concrete surface bughole based on deep learning[J]. Automation in Construction, 2019, 107: 102920.
- [11] OTSU N. A threshold selection method from gray-level histograms[J]. IEEE Transactions on Systems, Man, and Cybernetics, 1979, 9(1): 62 - 66.
- [12] 马丽莎. 基于数字图像处理的路面裂缝识别方法研究[硕士学位论文][D]. 南京: 东南大学, 2018.(MA Lisha Research on pavement crack recognition method based on digital image processing[M. S. Thesis][D]. Nanjing: Southeast University, 2018.(in Chinese))
- [13] LI Q, ZOU Q, ZHANG D, et al. FoSA: F* seed-growing approach for crack-line detection from pavement images[J]. Image and Vision Computing, 2011, 29(12): 861 - 872.
- [14] ALEKSEYCHUK O. Detection of crack-like indications in digital radiography by global optimisation of a probabilistic estimation function[Ph. D. Thesis][D]. Zurich: Bundesanstalt für Materialforschung und-prüfung(BAM), 2006.
- [15] FUJITA Y, MITANI Y, HAMAMOTO Y. A method for crack detection on a concrete structure[C]//18th International Conference on Pattern Recognition (ICPR'06). Piscataway: IEEE, 2006: 901 - 904.
- [16] 刘学增, 桑运龙, 苏云帆. 基于数字图像处理的隧道渗漏水病害检测技术[J]. 岩石力学与工程学报, 2012, 31(增 2): 3 779 - 3 786. (LIU Xuezeng, SANG Yunlong, SU Yunfan. Tunnel leakage disease detection technology based on digital image processing[J]. Chinese Journal of Rock Mechanics and Engineering, 2012, 31(Supp.2): 3 779 - 3 786.(in Chinese))
- [17] 彭 斌, 祝志恒, 阳军生, 等. 基于全景展开图像的隧道衬砌渗漏水数字化识别方法研究[J]. 现代隧道技术, 2019, 56(3): 31 - 37.(PENG Bin, ZHU Zhiheng, YANG Junsheng, et al. On digital identification of water leakage at tunnel lining based on the panoramic developed image[J]. Modern Tunnel Technology, 2019, 56(3): 31 - 37.(in Chinese))
- [18] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[C]// Proceedings of the 25th International Conference on Neural Information Processing Systems. New York: Curran Associates Inc, 2012: 1 - 9.
- [19] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]// Proceedings of the IEEE Conference On Computer Vision and Pattern Recognition. Piscataway: IEEE, 2015: 1 - 9.
- [20] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[C]// International Conference on Learning Representations. San Diego: ICLR, 2015: 1 - 14..
- [21] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 770 - 778.
- [22] 薛亚东, 李宜城. 基于深度学习的盾构隧道衬砌病害识别方法[J]. 湖南大学学报: 自然科学版, 2018, 45(3): 100 - 109.(XUE Yadong, LI Yicheng. A method of disease recognition for shield tunnel lining based on deep learning[J]. Journal of Hunan University: Natural Sciences, 2018, 45(3): 100 - 109.(in Chinese))
- [23] WANG W, HU W, WANG W, et al. Automated crack severity level detection and classification for ballastless track slab using deep convolutional neural network[J]. Automation in Construction, 2021, 124: 103484.
- [24] SILVA W R L, LUCENA D S. Concrete cracks detection based on deep learning image classification[C]// Proceedings of the Multidisciplinary Digital Publishing Institute. Basel: MDPI, 2018, 2(8): 489.
- [25] LIU W, ANGUELOV D, ERHAND, et al. Ssd: Single shotmultibox detector[C]// European conference on computer vision. Cham : Springer, 2016: 21 - 37.
- [26] REDMON J, FARHADIA. YOLO9000: better, faster, stronger[C]// IEEE Conference on Computer Vision and Pattern Recognition. Hawaii, USA: IEEE, 2017: 6 517 - 6 525.
- [27] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]// Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE, 2016: 779 - 788.
- [28] REDMON J, FARHADI A. YOLOv3: an incremental improvement[J]. arXiv preprint arXiv, 2018, <http://doi.org/10.48550/arXiv.1804.02767>.
- [29] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]// IEEE Conference on Computer Vision and Pattern Recognition. Los

- Alamitos, CA: IEEE Computer Society, 2014: 580 – 587.
- [30] GIRSHICK R. Fast R-CNN[C]// Proceedings of the IEEE International Conference on Computer Vision. Piscataway: IEEE, 2015: 1 440 – 1 448.
- [31] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39(6): 1 137 – 1 149.
- [32] 任 松, 朱倩雯, 涂歆玥, 等. 基于深度学习的公路隧道衬砌病害识别方法[J]. 浙江大学学报: 工学版, 2022, 56(1): 92 – 99.(REN Song, ZHU Qingwen, TU Xinyue, et al. Lining disease identification of highway tunnel based on deep learning[J]. Journal of Zhejiang University: Engineering Science, 56(1): 92 – 99.(in Chinese))
- [33] DENG J, LU Y, LEE V C S. Concrete crack detection with handwriting script interferences using faster region-based convolutional neural network[J]. Computer-Aided Civil and Infrastructure Engineering, 2020, 35(4): 373 – 388.
- [34] ZHOU Z, ZHANG J, GONG C. Automatic detection method of tunnel lining multi-defects via an enhanced You Only Look Once network[J]. Computer-Aided Civil and Infrastructure Engineering, 2022, 37(6): 762 – 780.
- [35] FENG C, ZHANG H, LI Y, et al. Efficient real-time defect detection for spillway tunnel using deep learning[J]. Journal of Real-Time Image Processing, 2021, 18(6): 1 – 11.
- [36] 黄宏伟, 李庆桐. 基于深度学习的盾构隧道渗漏水病害图像识别[J]. 岩石力学与工程学报, 2017, 36(12): 2 861 – 2 871.(HUANG Hongwei, LI Qingtong. Image recognition for water leakage in shield tunnel based on deep learning[J]. Chinese Journal of Rock Mechanics and Engineering, 2017, 36(12): 2 861 – 2 871.(in Chinese))
- [37] ZHANG L, SHEN J, ZHU B. A research on an improved Unet-based concrete crack detection algorithm[J]. Structural Health Monitoring, 2021, 20(4): 1 864 – 1 879.
- [38] CHEN L, ZHU Y, PAPANDREOU G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]// European Conference on Computer Vision. Berlin, German: Springer, 2018: 801 – 818.
- [39] CHOLLET F. Xception: Deep learning with depthwise separable convolutions[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2017: 1 251 – 1 258.
- [40] YU F, KOLTUN V. Multi-scale context aggregation by dilated convolutions[J]. arXiv preprint arXiv, 2015, <https://doi.org/10.48550/arXiv.1511.07122>.
- [41] CHEN L C, PAPANDREOU G, KOKKINOS I, et al. Semantic image segmentation with deep convolutional nets and fully connected CRFs[J]. arXiv preprint arXiv, 2014, <https://doi.org/10.48550/arXiv.1412.7062>.
- [42] CHEN L C, PAPANDREOU G, SCHROFF F, et al. Rethinking atrous convolution for semantic image segmentation[J]. arXiv preprint arXiv, 2017, <https://doi.org/10.48550/arXiv.1706.05587>.
- [43] TAN M, LE Q. Efficientnetv2: Smaller models and faster training[C]// International Conference on Machine Learning. New York: PMLR, 2021: 10 096 – 10 106.
- [44] WOOS, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[C]// Proceedings of the European conference on computer vision(ECCV). Berlin: Springer, 2018: 3 – 19.
- [45] TAN M, LE Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]// International Conference on Machine Learning. New York: PMLR, 2019: 6 105 – 6 114.
- [46] RUSSELL B C, TORRALBA A, MURPHY K P, et al. LabelMe: a database and web-based tool for image annotation[J]. International Journal of Computer Vision, 2008, 77(1): 157 – 173.
- [47] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]// Proceedings of the IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 2 980 – 2 988.
- [48] LIASHCHYNSKYI P, LIASHCHYNSKYI P. Grid search, random search, genetic algorithm: A big comparison for NAS[J]. arXiv preprint arXiv, 2019, <https://doi.org/10.48550/arXiv.1912.06059>.